TECNOLÓGICO NACIONAL DE MÉXICO
INSTITUTO TECNOLÓGICO DE POCHUTLA

Carrera: Ingeniería en Sistemas Computacionales

ACTIVIDAD T3-01. PROGRAMACIÓN NO LINEAL

Reporte técnico: mapa conceptual y esquema de optimización clásica

Alumno: [Daniel Vazquez Leon]
Materia: Investigación de Operaciones
Docente: [Salmoran]
Lugar y fecha: San Pedro Pochutla, Oaxaca, 26/10/2026

Índice

1. Introducción **3**

2. Desarrollo **3**

2.1. Mapa conceptual de la programación no lineal 3

2.1.1. Planteamiento general 3

2.1.2. Ilustración gráfica y diferencias con la programación lineal 4

2.1.3. Clasificación de los problemas no lineales 5

2.2. Esquema analítico de la optimización clásica 6

2.2.1. Máximos, mínimos y puntos de inflexión 6

2.2.2. Criterio de la primera derivada 7

2.2.3. Criterio de la segunda derivada 7

2.2.4. Multiplicadores de Lagrange (restricciones de igualdad) 8

3. Conclusión **9**

Fuentes de información **11**

1. Introducción

La programación lineal supone que la función objetivo y todas las restricciones son lineales. Esa hipótesis simplifica el cálculo, pero muchos problemas reales no la cumplen. Los costos unitarios bajan al producir en volumen, el rendimiento de una inversión depende del riesgo de forma cuadrática y las pérdidas por fricción en una tubería crecen con el cuadrado del caudal. En estos casos, un modelo lineal solo es una aproximación (Hillier y Lieberman, 2015).

La programación no lineal (PNL) permite modelar esos fenómenos sin linealizarlos. En ingeniería se usa para diseñar estructuras de peso mínimo, ajustar parámetros de modelos de aprendizaje automático, optimizar procesos químicos y distribuir recursos en redes eléctricas o de cómputo. En la toma de decisiones se usa para construir portafolios de inversión de mínima varianza y para fijar precios con demanda elástica (Winston, 2005).

Este reporte presenta dos esquemas. El primero es un mapa conceptual de la PNL: definición, diferencias con la programación lineal (PL) y clasificación de los problemas. El segundo es un esquema analítico de la optimización clásica, con máximos, mínimos, puntos de inflexión, los criterios de la primera y la segunda derivada y el método de multiplicadores de Lagrange. Cada esquema va acompañado de una explicación técnica y de un ejemplo resuelto.

2. Desarrollo

2.1. Mapa conceptual de la programación no lineal

2.1.1. Planteamiento general

Un problema de programación no lineal busca

$$\begin{aligned} \text{optimizar} \quad & f(x_1, \ldots, x_n) \\ \text{sujeto a} \quad & g_i(x_1, \ldots, x_n) \le b_i, \quad i = 1, \ldots, m, \end{aligned} \tag{1}$$

donde al menos una de las funciones f o g_i es no lineal en las variables de decisión (Hillier y Lieberman, 2015). Los modelos con restricciones de igualdad se escriben como $h_j(\mathbf{x}) = 0$.

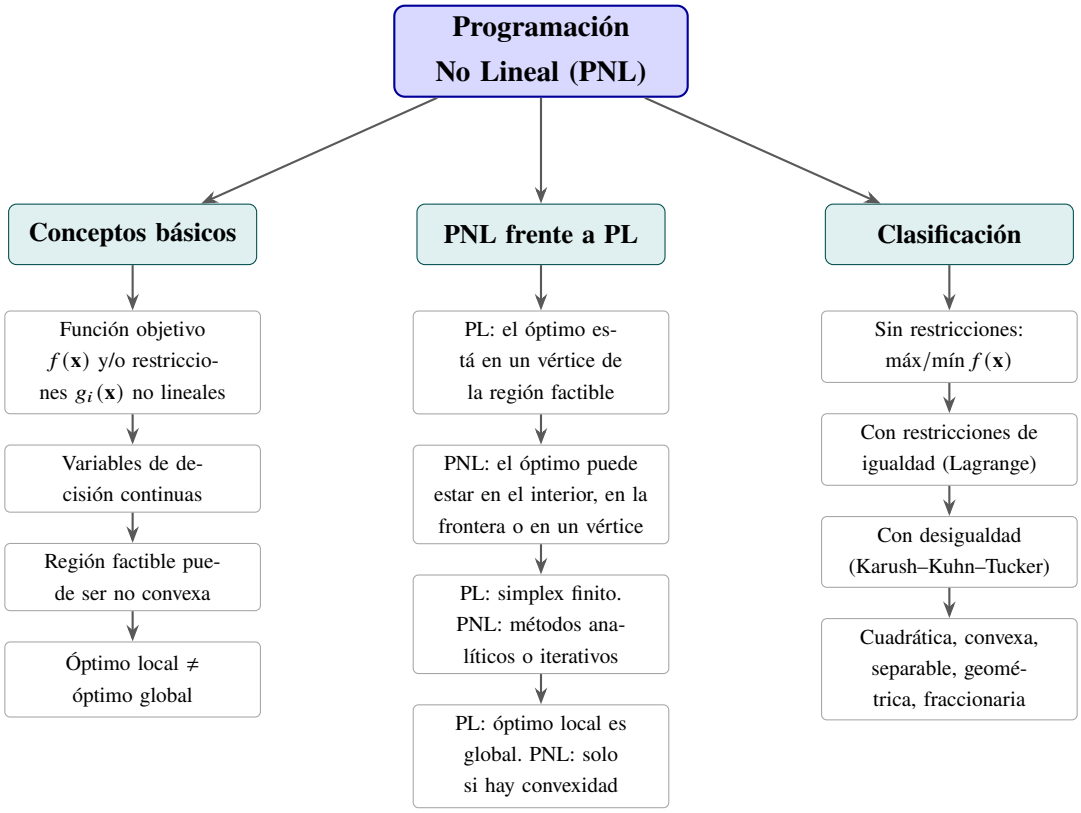


Figura 1: Mapa conceptual de la programación no lineal. Elaboración propia con base en Hillier y Lieberman (2015), Taha (2017) y Winston (2005).

2.1.2. Ilustración gráfica y diferencias con la programación lineal

En PL, las curvas de nivel de f son rectas paralelas y la región factible es un poliedro. El óptimo se alcanza siempre en un vértice, de modo que basta recorrer vértices adyacentes (método simplex). En PNL, las curvas de nivel pueden ser círculos, elipses u otras curvas. El óptimo puede quedar en un punto de tangencia entre una curva de nivel y la frontera, o incluso dentro de la región factible (Taha, 2017). La figura 2 compara ambos casos.

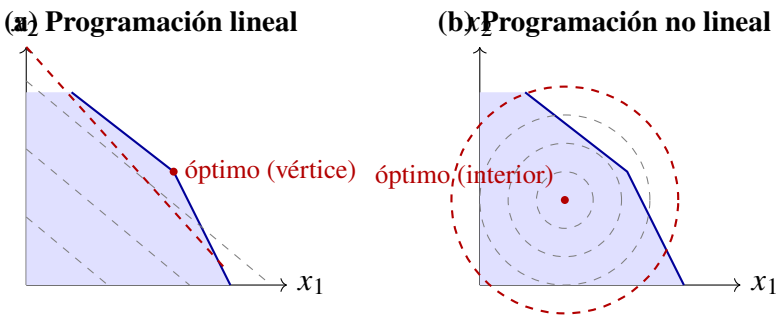


Figura 2: (a) En PL el óptimo está en un vértice. (b) En PNL, con curvas de nivel circulares, el óptimo puede estar en el interior de la región factible. Elaboración propia.

Tabla 1: Comparación entre programación lineal y no lineal

Aspecto	**Programación lineal**	**Programación no lineal**
Funciones	f y g_i lineales	Al menos una no lineal
Región factible	Poliedro convexo	Puede ser no convexa
Ubicación del óptimo	Siempre en un vértice	Interior, frontera o vértice
Óptimos	Todo óptimo local es global	Puede haber varios óptimos locales
Método de solución	Simplex (finito, exacto)	Cálculo diferencial, gradiente, KKT, métodos iterativos
Garantía de solución	Alta	Depende de la convexidad y del punto inicial

2.1.3. Clasificación de los problemas no lineales

Según Hillier y Lieberman (2015), los problemas de PNL se clasifican por la forma de f y de las restricciones:

- **Optimización sin restricciones:** no hay g_i y se resuelve con las condiciones de primer y segundo orden.
- **Con restricciones de igualdad:** se resuelve con multiplicadores de Lagrange.
- **Con restricciones de desigualdad:** se resuelve con las condiciones de Karush–Kuhn–Tucker (KKT).
- **Programación cuadrática:** f es cuadrática y las restricciones son lineales.

- **Programación convexa:** f es cóncava (en maximización) o convexa (en minimización) y la región factible es convexa. Aquí todo óptimo local es global.
- **Programación separable:** $f(\mathbf{x}) = \sum_j f_j(x_j)$, lo que permite aproximarla por tramos lineales.
- **Programación geométrica y fraccionaria:** la función objetivo es un posinomio o un cociente de funciones.

2.2. Esquema analítico de la optimización clásica

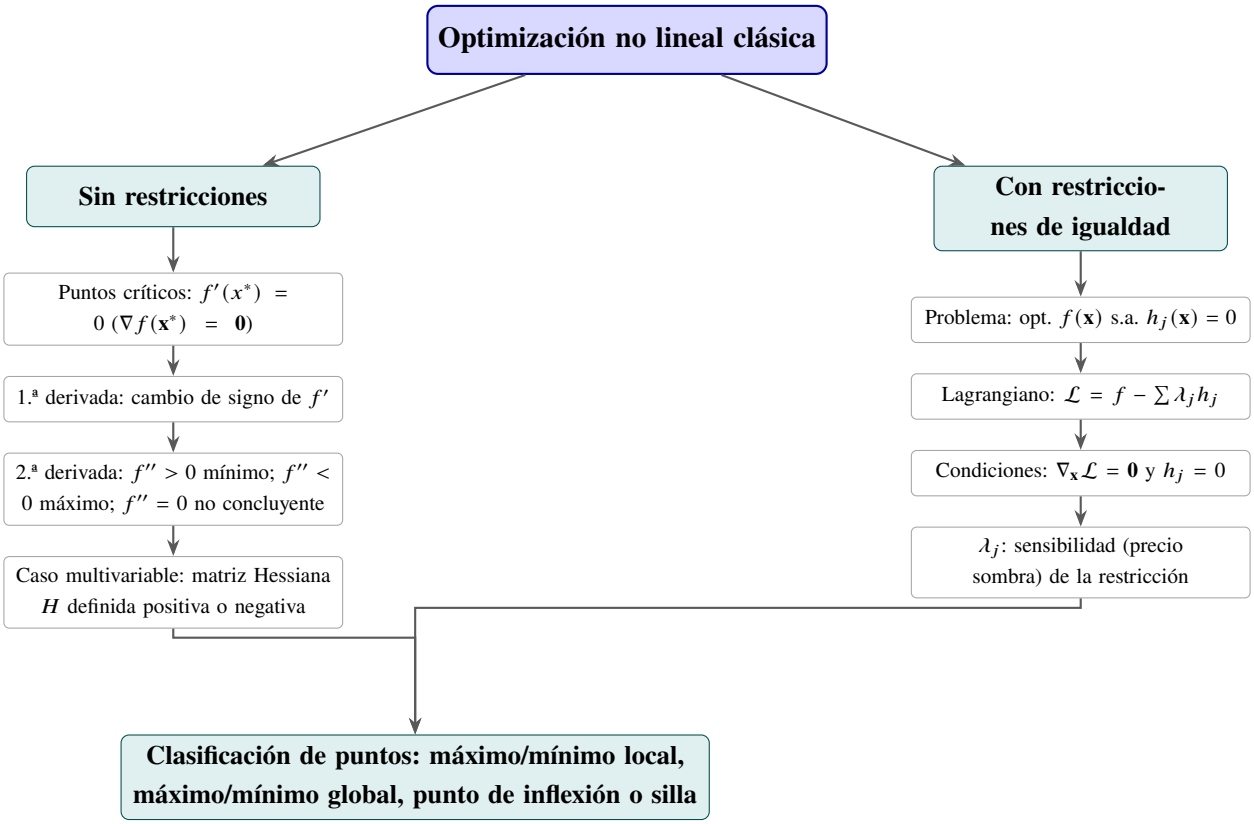


Figura 3: Esquema analítico de la optimización no lineal clásica. Elaboración propia con base en Taha (2017) y Bazaraa et al. (2006).

2.2.1. Máximos, mínimos y puntos de inflexión

Sea $f : \mathbb{R} \to \mathbb{R}$ diferenciable.

- x^* es un **mínimo local** si $f(x^*) \leq f(x)$ para todo x en un entorno de x^*. Es un **máximo local** si $f(x^*) \geq f(x)$ en un entorno.

- x^* es un **mínimo global** (o máximo global) si la desigualdad se cumple en todo el dominio factible. Todo óptimo global es local, pero lo contrario no se cumple en general.
- Un **punto de inflexión** es aquel donde la concavidad cambia (f'' cambia de signo). Si además $f'(x^*) = 0$, no es máximo ni mínimo y se llama punto de silla o de inflexión horizontal (Winston, 2005).

La figura 4 ilustra estos conceptos con $f(x) = x^3 - 3x$.

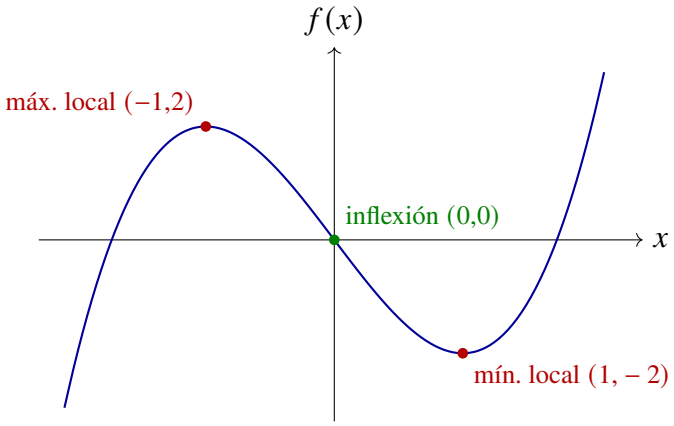


Figura 4: Gráfica de $f(x) = x^3 - 3x$ con sus extremos locales y su punto de inflexión. No hay extremos globales porque $f \to \pm\infty$.

2.2.2. Criterio de la primera derivada

Los candidatos a extremo son los *puntos críticos*, donde $f'(x^*) = 0$ (condición necesaria de primer orden). Para clasificarlos se observa el signo de f' alrededor de x^*:

- si f' pasa de positiva a negativa, x^* es un máximo local;
- si f' pasa de negativa a positiva, x^* es un mínimo local;
- si f' no cambia de signo, x^* no es un extremo.

2.2.3. Criterio de la segunda derivada

Si $f'(x^*) = 0$, entonces:

- $f''(x^*) > 0 \Rightarrow$ mínimo local (la función es localmente convexa);
- $f''(x^*) < 0 \Rightarrow$ máximo local (la función es localmente cóncava);

- $f''(x^*) = 0 \Rightarrow$ el criterio no concluye y se recurre a derivadas de orden superior o a la primera derivada.

Para $f : \mathbb{R}^n \to \mathbb{R}$, la condición necesaria es $\nabla f(\mathbf{x}^*) = \mathbf{0}$. La clasificación se hace con la matriz Hessiana $H = \left[\partial^2 f / \partial x_i \partial x_j\right]$: si H es definida positiva, el punto es un mínimo local; si es definida negativa, un máximo local; si es indefinida, un punto de silla (Bazaraa et al., 2006).

Ejemplo. Para $f(x) = x^3 - 3x$ se tiene $f'(x) = 3x^2 - 3 = 0 \Rightarrow x = \pm 1$ y $f''(x) = 6x$.

- $f''(-1) = -6 < 0$, así que $x = -1$ es un máximo local con $f(-1) = 2$.
- $f''(1) = 6 > 0$, así que $x = 1$ es un mínimo local con $f(1) = -2$.
- $f''(x) = 0$ en $x = 0$ y f'' cambia de signo, así que $x = 0$ es un punto de inflexión con $f(0) = 0$.

Óptimos globales. Si f es convexa (para mínimo) o cóncava (para máximo) en el conjunto factible, el óptimo local es global. En otros casos se comparan los valores de f en los puntos críticos y en la frontera del dominio.

2.2.4. Multiplicadores de Lagrange (restricciones de igualdad)

Para optimizar $f(\mathbf{x})$ sujeta a $h_j(\mathbf{x}) = 0$, $j = 1, \ldots, m$, se define el lagrangiano

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) - \sum_{j=1}^{m} \lambda_j \, h_j(\mathbf{x}). \tag{2}$$

Las condiciones necesarias de óptimo son $\partial \mathcal{L} / \partial x_i = 0$ para cada i y $h_j(\mathbf{x}) = 0$ para cada j. Geométricamente, en el óptimo el gradiente de f es combinación lineal de los gradientes de las restricciones, es decir, las curvas de nivel de f son tangentes a la restricción. El multiplicador λ_j indica cuánto cambia el valor óptimo de f por cada unidad que se relaja el lado derecho de la restricción (Hillier y Lieberman, 2015).

Ejemplo. Minimizar $f(x, y) = x^2 + y^2$ sujeta a $x + y = 2$.

1. Lagrangiano: $\mathcal{L} = x^2 + y^2 - \lambda(x + y - 2)$.
2. Derivadas parciales:

$$\frac{\partial \mathcal{L}}{\partial x} = 2x - \lambda = 0, \qquad \frac{\partial \mathcal{L}}{\partial y} = 2y - \lambda = 0, \qquad x + y = 2.$$

3. De las dos primeras, $x = y = \lambda/2$. Al sustituir en la restricción, $\lambda = 2$ y por tanto $x^* = y^* = 1$.

4. Valor óptimo: $f(1,1) = 2$. El punto es un mínimo porque f es convexa y la restricción es lineal, de modo que el mínimo local es global.

5. Interpretación: si el lado derecho pasa de 2 a $2 + \Delta$, el mínimo cambia aproximadamente $\lambda\,\Delta = 2\Delta$. En efecto, el mínimo exacto es $\Delta'^2/2$ con $\Delta' = 2 + \Delta$, y su derivada en $\Delta' = 2$ vale 2.

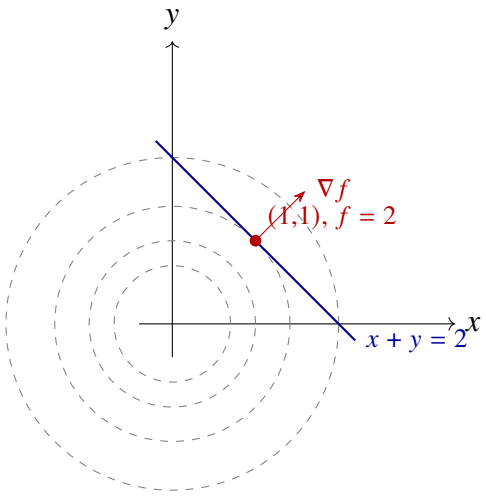


Figura 5: Solución geométrica del ejemplo: la circunferencia $x^2 + y^2 = 2$ es tangente a la restricción en $(1,1)$.

3. Conclusión

Los modelos no lineales representan con más fidelidad los fenómenos donde hay economías de escala, rendimientos decrecientes, riesgo, fricción o interacciones entre variables. Esa fidelidad tiene un costo: la PNL no ofrece las garantías de la PL. El simplex termina en un número finito de pasos y encuentra el óptimo global. En cambio, un método de PNL puede quedar atrapado en un óptimo local, depender del punto inicial o no converger. Solo bajo convexidad se recupera la garantía de que lo local es global (Bazaraa et al., 2006).

Los métodos clásicos estudiados en este reporte, es decir, las derivadas y los multiplicadores de Lagrange, permiten resolver problemas pequeños de forma exacta y dan un resultado extra: el multiplicador λ cuantifica el valor marginal de cada restricción. Su limitación es que exigen funciones diferenciables y sistemas de ecuaciones que, en problemas grandes, no se pueden resolver a mano. Por eso en la práctica se usan algoritmos numéricos y software de optimización (Taha, 2017).

La PL sigue siendo la mejor opción cuando la linealidad es una aproximación razonable, porque es más rápida, más robusta y permite análisis de sensibilidad directo. La PNL es preferible cuando la no linealidad es esencial para el problema, como en el diseño de ingeniería, las finanzas, el control de procesos y el entrenamiento de modelos de aprendizaje automático. En esos casos conviene verificar la convexidad del modelo y probar varios puntos iniciales antes de aceptar un resultado como óptimo global.

Fuentes de información

Bazaraa, M. S., Sherali, H. D. y Shetty, C. M. (2006). *Nonlinear programming: Theory and algorithms* (3.ª ed.). John Wiley & Sons.

Hillier, F. S. y Lieberman, G. J. (2015). *Introduction to operations research* (10.ª ed.). McGraw-Hill Education.

Taha, H. A. (2017). *Operations research: An introduction* (10.ª ed.). Pearson.

Winston, W. L. (2005). *Investigación de operaciones: Aplicaciones y algoritmos* (4.ª ed.). Cengage Learning.